

数学学院案例分析报告

案例名称：脑电数据情感分析

报告负责人：魏丹怡 (202032164)

完成时间：2021.04.28

目 录

一、绪论.....	1
1、研究背景.....	1
2、情感理论.....	1
3、研究意义.....	1
二、数据来源和基本情况.....	2
1、数据来源.....	2
2、基本情况.....	2
三、数据预处理.....	2
1、情感分类.....	2
2、EEG 信号提取.....	3
3、短时傅里叶变换.....	3
4、特征提取.....	4
5、特征可视化.....	5
四、情感分类.....	5
1、形式化和分类器数学推导.....	6
2、计算机仿真过程.....	7
3、评估方法和数据划分.....	7
4、分类结果和比较统计.....	8
五、结果分析和得出结论.....	10
六、实践总结.....	10

一、绪论

1、研究背景

利用计算机技术进行情感识别是实现高级人机交互的关键技术，对于实现人机交互、人一计算机接口以及智能计算机等有重要意义。情感识别主要通过面部表情、语音、姿势、文本和生理信号等来实现。基于面部表情和语音等外在信号的研究由来已久，但其结果一般会受人的主观因素影响，人体的生理变化主要受自主神经系统和内分泌系统支配，而很少受人的主观控制，因此应用生理信号进行情感识别所得到的结果更加客观。目前国内外采用的生理信号主要有脑电(EEG)、心电(ECG)、肌电(EMG)、血容量脉搏(BVP)、皮肤电反应(GSP)、眼动(EOG)等。

2、情感理论

罗莎琳德·皮卡德在情感计算一书中说“源于或有意影响于情感的计算机运算称为情感计算”。情感计算不同于提出一种情感理论，情感理论通常关注情感是什么、情感是怎样产生的以及情感怎样发展。而情感计算包括许多其他的方面，如赋予计算机识别和表达情感的能力等，要相对情感进行准确地评测，必须合理的建立情感模型。

在情感处理领域的主要模型有两种，一种是连续的情感模型，一种是离散的情感模型。离散情感模型认为存在着几种基本情感，每一种基本情感是一个离散的实体。每种情感都有特定的生理模式，其他各种情感都由这些基本情感不同程度的修改组合而成。连续情感模型认为每种情感都是一个连续体上的一部分，不同的情感对应一个二维或三维空间上的一点，在研究中往往只考虑二维。现在最常见的连续情感模型是兰格的二维情感分类模型，这个模型用横坐标来表示人们心情的愉悦程度，用纵坐标来表示状态的兴奋程度，程度都是由低到高，这样不同的情感就可以分解成两个维度映射到坐标系中。




图1 兰格的情感分类模型

3、研究意义

基于生理信号的情感分类从某种意义上讲，就是寻求生理信号特征模式与情感状态之间的映射关系。如果找到能够准确表征某种情感的特征模式或某些特定的特征，这些特征就可以用来进行情感分类与情感识别，从而实现人机情感的和谐交互。

Picard 在 MIT 媒体实验室的技术报告中给出了人机情感和谐交互的至少 50 种应用:情感教学，情感玩具，情感眼镜，情感鼠标等等。情感识别可以帮助我们增加设备使用的安全性，减少因情感因素所造成的安全事故，如可以检测司机是否处于安全的情感状态，以确保列车行驶安全。人机情感交互使得计算机的许多应用更加方便可行，因为计算机只需通过人

二、数据来源和基本情况

此数据集为“DEAP 数据集”中的一部分，来自 32 名志愿者的脑电图（EEG）和周围生理信号。他们每人观看了 40 个长达 1 分钟的音乐录影带摘录，以 128Hz 为采样频率，采集了志愿者的脑电数据。共记录了 1280 个单通道的脑电情感数据，即 EEG 时间序列信号数据。

此数据集共有 1280 个样本，每个样本包括 7680 个数据，为 60 秒内采集到的 EEG 时间序列信号数据，此外，文件最后两列记录每个样本情感标签，即 Valance 和 Arousal 两个维度情感得分。

三、数据预处理

根据文件最后两列记录的 Valance 和 Arousal 两个维度情感得分,我们按照兰格的情感分类模型对样本进行分类,情感类别划分标准如下:

情感	划分规则	标签
兴奋	Valance>5 Arouce>5	0
愤怒	Valance≤5 Arouce>5	1
轻松	Valance>5 Arouce≤5	2
厌烦	Valance≤5 Arouce≤5	3

不同的情感如果被合理利用就可以产生可观的价值,例如将上述情感分类应用在打游戏场景中,兴奋的情感可以让我们更快的接近胜利,二愤怒的情感却可能会产生冲动,从而不利于获得胜利。

2、EEG 信号提取

常用的脑电特征是时域特征、频域特征和时一频特征。所谓时域特征,是将脑电信号在时域上的信息直接作为特征或将时域上的信号统计结果作为特征(如峰值、方差等)。频域特征是指将原始脑电信号从时域转化到频域,再提取有关频域特性作为脑电特征。

神经科学和心理学的研究表明脑电的 δ 频带(1-4Hz)、 θ 频带(4-8Hz)、 α 频带(8-13Hz)、 β 频带(13-30Hz)和 γ 频带(36-45Hz)五个频带与人的各项生理及心理活动有着密切的关系。人脑在不同状态下的脑电图特征包括:

(1) 清醒状态:人在清醒状态时,安静并且闭眼,皮层脑电活动脑电图以 α 波为主,睁开眼睛或接受刺激时, α 波立即消失,而呈现 β 波,这一现象称为 α 波阻断。如果被试又安静闭眼时,则 α 波又重现。此时人的肌肉系统伴有高度的紧张性。在困倦时,一般可见到 θ 波。成人在清醒状态下,几乎没有 δ 波。

(2) 慢波睡眠:皮层脑电活动脑电图呈现高幅慢波,此时期肌肉仍然保持一定的紧张性,这是一种浅睡眠状态。由于此时期无眼球快速转动的现象,因此慢波睡眠又称为非快眼动相睡眠。又由于此期脑电图呈现慢波形式,这可能是无数皮层神经自发电活动节律同步化的结果,因此慢波睡眠还被称为同步睡眠。慢波睡眠 1-4 期的睡眠程度由浅入深,其脑电图特点发生如下变化:

慢波 1 期:当人逐渐进入睡眠的慢波 1 期时,脑电图就变得比较不大规则,并且振幅降低,只有少量 α 波或者根本没有 α 波了,呈现 θ 波;

慢波 2 期:在 θ 波的背景上呈现 σ 梭形波和“K-复合体”波;

慢波 3 期:进入深睡眠阶段,脑电波特征是呈现高振幅的波,呈现 δ 波指数为 20-50%。也可见到 σ 波呈现;

慢波 4 期:同慢波 3 期, δ 波指数超过 50%,处于慢波 3-4 的人变得更加难叫醒。

利用现代功率谱分析方法,从频域信息中可以获取与特定脑活动关联的不同频率频带的变化。具体而言是指将脑电信号映射到以上五个频带,再提取各个频带所对应的频域特征。在基于脑电的情感分类研究中,最常用的频带有五个,即 δ (1-4Hz)、 θ (4-8Hz)、 α (8-13Hz)、 β (13-30Hz)、 γ (36-45Hz),不同频带脑电信号的特征是不同的。常见的频域特征有功率谱,功率谱密度,能量等。这些特征的提取通常都建立在功率谱估计的基础上。以一定时间段脑电数据的傅里叶变换作为处理基础的估计法是比较经典的功率谱估计方法。

3、短时傅里叶变换

对于原始的脑电信号,已经得到了信号在每一个采样时刻的幅值。如果想知道在每个频率处信号的能量成分,则需要用傅里叶变换将信号从时域转换到频域,即可得到信号在每个频率的能量。

以第一个样本为例,我们对其进行傅里叶变换,信号的前半部分对应频率 $[0, f_s/2]$,后半部分对应 $[-f_s/2, 0]$,结果如下:




图 2 傅里叶变换

然而,对整个信号进行傅里叶变换,将会丢失重要的时域信息,得到整个时间段的频谱。为了得到反映信号在不同时刻的功率谱信息,利用短时傅里叶变换(STFT)的方法来绘制信号的时频图,提取脑电信号在每个频段上能量的总值作为脑电特征。

设置采样频率为 128、窗口大小为 256、窗口重叠大小为 128,脑电信号经短时傅里叶变换后的时频图如下所示,其中三维图的 Z 轴为对 P 值(功率谱密度 PSD)取对数($10\log$):

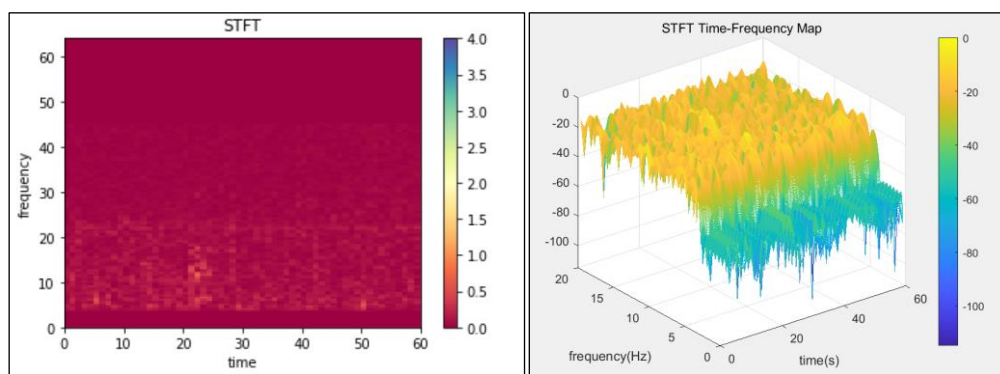


图 3 短时傅里叶变换时频图

在此基础上,采用周期图法计算功率谱,纵坐标进行了取对数的处理($10\log$),目的是使那些振幅较低的成分相对高振幅成分得以拉高,以便观察掩盖在低幅噪声中的信号特征。




图 4 功率谱

4、特征提取

在利用傅里叶变换将信号转换至频域后,我提取了 delta、theta、alpha、beta 和 gamma 这 5 个频带的 PSD 特征,此外,还对脑电信号数据提取了峰度、偏度、均值、标准差这 4 个统计学特征,采用上述 9 个特征进行后续的情感分类。

表 2 特征

	delta	theta	alpha	beta	gamma	skew	kurtosis	mean	std	label
0	0.098236	15.437474	19.688142	19.167326	0.946726	0.077424	1.273959	1.547428e-04	0.999908	0
1	0.624582	54.902627	34.854884	9.437193	2.951141	-0.038092	1.088403	9.677692e-05	0.999964	0
2	2.256286	16.207363	34.347666	14.589922	1.842068	0.033451	0.661738	1.262117e-04	0.999939	0
3	2.185748	8.928470	23.687655	22.961534	2.005770	-0.015392	0.691096	2.035617e-04	0.999841	1
4	1.703773	10.845313	10.423890	15.169374	2.152532	-0.051136	0.410896	-1.553952e-04	0.999907	2
...
1275	0.110368	16.340839	10.834305	6.216542	1.513464	0.187948	5.634002	-1.892955e-05	0.999999	1
1276	25.496551	194.954126	34.909483	15.316454	3.658594	0.450609	8.423196	-1.315275e-07	1.000000	1
1277	3.877651	206.823189	54.830019	14.798659	4.486835	0.290504	5.307638	6.935460e-04	0.998151	1
1278	0.590835	27.100986	19.054744	9.403898	3.735829	0.200992	3.622110	-1.717476e-04	0.999887	1
1279	0.191916	8.566379	11.758612	9.374302	1.146595	0.243428	7.197034	1.531931e-04	0.999910	2

1280 rows × 10 columns

5、特征可视化

将数据描述表示从表格转化为图像形式如下小提琴图所示。小提琴图结合了箱形图和密度图的特征，主要用来显示数据的分布形状。中间白点为中位数，中间的黑色粗条表示四分位数范围。上下贯穿小提琴图的黑线代表最小非异常值 min 到最大非异常值 max 的区间，线上下端分别代表上限和下限，超出此范围为异常数据，其中颜色的部分为密度图宽。




图 5 小提琴图

上图中纵坐标代表脑电特征，横坐标代表四种情感。从左到右、从上到下各图中的纵坐标依次为 δ 特征、 θ 特征、 α 特征、 β 特征、 γ 特征、样本偏度、样本峰度、样本均值和样本标准差。由图可以看出，四种情感在每个特征下的表现均相差不大，因此我们选取全部特征进行分类分析。

四、情感分类

1、形式化和分类器数学推导

(1) SVM 算法

运用支持向量机实现一个多分类问题，使用一对多的方法，即训练时依次把某个类别的样本归为一类，其他剩余的样本归为另一类，这样 k 个类别的样本就构造出了 k 个 SVM。在此案例中，要将脑电信号按情感不同分为四类（记为 0、1、2、3），于是抽取训练集的时候，分别抽取：

- (a) 0 所对应的向量作为正集，1、2、3 所对应的向量作为负集；
- (b) 1 所对应的向量作为正集，0、2、3 所对应的向量作为负集；
- (c) 2 所对应的向量作为正集，0、1、3 所对应的向量作为负集；
- (d) 3 所对应的向量作为正集，0、1、2 所对应的向量作为负集；

使用这四个训练集分别进行训练，得到四个训练结果。在测试的时候，把对应的测试向量分别利用这三个训练结果文件进行测试。最后每个测试都有一个结果，最终的结果便是这三个值中最大的一个作为分类结果。

将脑电信号的属性以坐标形式表示，建立以下支持向量机模型：

$$\begin{aligned} \min_{w,b,\zeta} \quad & \frac{1}{2} w^T w + C \sum_{i=1}^n \zeta_i \\ \text{subject to} \quad & y_i(w^T \phi(x_i) + b) \geq 1 - \zeta_i, \\ & \zeta_i \geq 0, i = 1, \dots, n \end{aligned}$$

其中参数 C 代表在线性不可分的情况下，对分类错误的惩罚程度。 ζ_i 是对于第 i 样本点的分类损失，如果分类正确则是 0，如果分类有所偏差则对应一个线性的值， ζ_i 的求和是总误差，优化的目标当这个值越小越好，越小代表对训练集的分类越精准。目标函数中另一项的最小化的优化方向则是使间隔大小最大。

(2) Logistic Regression 算法

逻辑回归是监督学习中的一种，它根据大量带有分类标签的特征变量来训练优化模型，在根据模型来预测只有特征变量的分类标签。在脑电信号情感分类案例中，通过许多带有分类标签（信用状况有四种类别）的特征变量数据来训练预测信用状况类别的模型。为实现预测分类问题，使用了 Logistic 模型及 Sigmoid 函数：

$$\log_i(Z) = \frac{1}{1 + e^{-z}}$$

Sigmoid 函数有一些特点，比如当 $z = 0$ 是 $\log_i(z) = 0.5$ 当 $z < 0$ 时， $0 < \log_i(z) < 0.5$ ；当 $z > 0$ 时， $0.5 < \log_i(z) < 1$ 。所以 $\log_i(z)$ 函数的取值范围为 $(0,1)$ 。

其中回归的基本方程为：

$$z = w_0 + \sum_i^N w_i x_i$$

我们可以把 $\log_i(z)$ 的函数值看成类别为 1 的概率预测值，当 $\log_i(z) < 0.5$ 时，预测的分类为 0；当 $\log_i(z) \geq 0.5$ 时，预测的分类为 1。对于情感分类这种四分类问题，只需将三个二分类的逻辑回归组合即可实现。

2、计算机仿真过程

(1) SVM

在 jupyter notebook 中调用 `svc` 构建基于支持向量机的情感分类模型。

(2) Logistic Regression

在 jupyter notebook 中调用 `sklearn.linear_model` 包构建基于逻辑回归的情感分类模型。

3、评估方法和数据划分

(1) 混淆矩阵

混淆矩阵展示了查准率(准确率)与查全率(召回率)：

查准率(P) = $\frac{TP}{TP+FP}$ ，即在被判别为正类别的样本中，确实为正类别的比例是多少；

查全率(R) = $\frac{TP}{TP+FN}$ ，即在所有正类别样本中，被正确判别为正类别的比例是多少。

(2) ROC 曲线

模型训练完成之后，每个样本都会获得对应的两个概率值，一个是样本为正样本的概率，一个是样本为负样本的概率。把每个样本为正样本的概率取出来，进行排序，然后选定一个阈值，将大于这个阈值的样本判定为正样本，小于阈值的样本判定为负样本，可以得到两个值，一个是真正率，一个是假正率：

真正率 (TPR) = $\frac{TP}{TP+FN}$ ，即模型判定为正样本且实际为正样本的样本数与所有的正样本数之比；

假正率 (FPR) = $\frac{FP}{TN+FP}$ ，即模型判定为正样本实际为负样本的样本数与所有的负样本数之比。

每选定一个阈值，就能得到一对真正率和假正率，由于判定为正样本的概率值区间为 $[0, 1]$ ，那么阈值必然在这个区间内选择，因此在此区间内不停地选择不同的阈值，重复这个过程，就能得到一系列的真正率和假正率，以这两个序列作为横纵坐标，即可得到 ROC 曲线了。而 ROC 曲线下方的面积，即为 AUC 值。

(3) 数据划分

在本案例中，共有 1280 个样本，其中特征为 0 的个数为 439 个，标签为 1 的个数为 298 个，标签为 2 的个数为 274 个，标签为 3 的个数为 269 个。我们将样本的 80% 划分为训练集，20% 划分为测试集，并训练集、测试集中正、负例的比例与原数据集尽量一致。划分结果如下：

```
0    369
1    234
2    214
3    207
Name: label, dtype: int64
0     70
3     67
1     64
2     55
Name: label, dtype: int64
```

4、分类结果和比较统计

(1) SVM

通过 Sklearn 的 SVC 模型对脑电信号数据集进行分类，分类结果如下：

Accuracy of SVM Classifier: 0.36328125					
	precision	recall	f1-score	support	
0	0.37	0.93	0.53	99	
1	0.00	0.00	0.00	55	
2	0.00	0.00	0.00	59	
3	0.11	0.02	0.04	43	
accuracy			0.36	256	
macro avg	0.12	0.24	0.14	256	
weighted avg	0.16	0.36	0.21	256	

可以看出，模型分类的精度只有 36%，通过混淆矩阵来观察预测分类和实际分类情况，绘制混淆矩阵的热点图如下：




图6 SVM 混淆矩阵

由上图可知，此模型存在严重的问题，即该模型将几乎所有样本都误分类为标签为 0 即兴奋这一类别中，而另外几种情感即愤怒、轻松、厌烦则只有寥寥几个样本分入且其查准率(P)分别为 0%、0%、11%。其查全率(R)更低仅有 0%、0%、2%。由此可见，针对本次划分的训练集与测试集而言，该分类结果并不理想，尤其是 1 与 2 两个标签，SVM 完全没有将任何样本划分进去。这不利于我们对于无标签脑电信号进行预测，并利用该预测结果进行情感分析。

之后，根据下面 4 种情况绘制 ROC 曲线对此模型进行评估。

下图中从左到右、从上到下各图依次为：

- (a) 0 所对应的向量作为正集，1、2、3 所对应的向量作为负集；
- (b) 1 所对应的向量作为正集，0、2、3 所对应的向量作为负集；
- (c) 2 所对应的向量作为正集，0、1、3 所对应的向量作为负集；
- (d) 3 所对应的向量作为正集，0、1、2 所对应的向量作为负集。

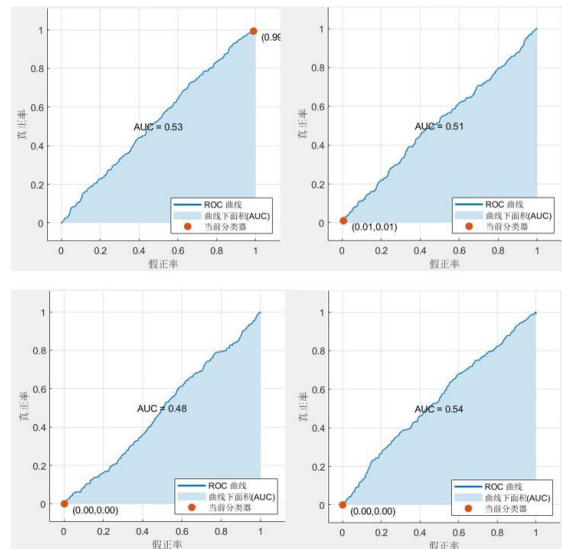


图7 SVM ROC 曲线

(2) Logistic Regression

通过 Sklearn 的 LogisticRegression 模型，取 $C=1000$ ， $\text{solver}='lbfgs'$ ，对脑电信号数据集进行分类，结果如下：

Accuracy of LR Classifier: 0.35546875					
	precision	recall	f1-score	support	
0	0.38	0.85	0.52	99	
1	0.16	0.05	0.08	55	
2	0.33	0.02	0.03	59	
3	0.27	0.07	0.11	43	
accuracy			0.36	256	
macro avg	0.29	0.25	0.19	256	
weighted avg	0.30	0.36	0.25	256	

可以看出，模型分类的精度只有 35%，通过混淆矩阵来观察预测分类和实际分类情况，绘制混淆矩阵的热点图如下：




图8 LR 算法混淆矩阵

由上图可知，此模型仍将多数样本全部分类为兴奋，相较于 SVM 模型的优点在于本次分类中兴奋、愤怒、轻松、厌烦四种情感都有样本分入，但其分类查准率与查全率仍旧处于较低水平。其中兴奋（标签为 0）的查准率为 38%，查全率为 85%，愤怒（标签为 1）的查准率为 16%，查全率为 5%，轻松（标签为 2）的查准率为 33%，查全率为 2%，厌烦（标签为 3）

的查准率为 27%，查全率为 7%。其查全率只有兴奋高而其他情感低的主要原因在于多数样本均被划分为兴奋这一情感中。

之后，根据下面 4 种情况绘制 ROC 曲线对此模型进行评估。

下图中从左到右、从上到下各图依次为：

- (a) 0 所对应的向量作为正集，1、2、3 所对应的向量作为负集；
- (b) 1 所对应的向量作为正集，0、2、3 所对应的向量作为负集；
- (c) 2 所对应的向量作为正集，0、1、3 所对应的向量作为负集；
- (d) 3 所对应的向量作为正集，0、1、2 所对应的向量作为负集。

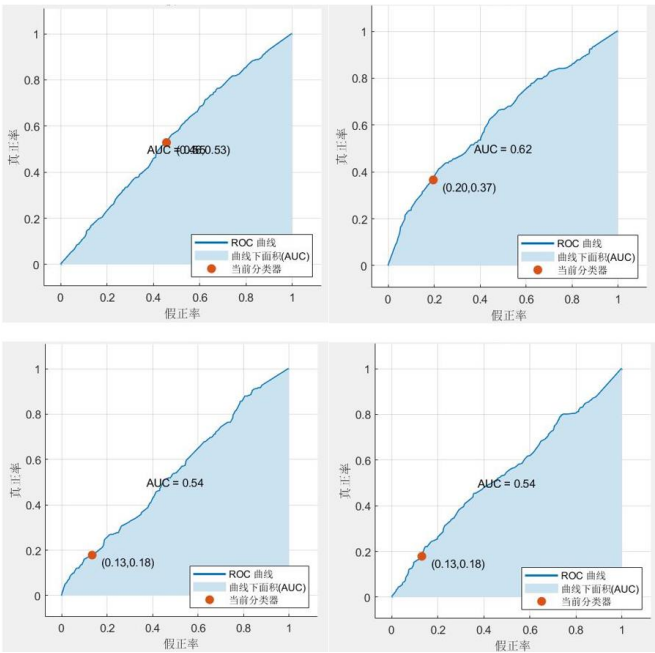


图 9 逻辑回归 ROC 曲线

五、结果分析和得出结论

本文以脑电数据集为实验数据，采用 SVM、逻辑回归模型对数据集进行分类。首先对于脑电信号数据利用短时傅里叶变换提取功率谱密度 PSD 以及脑电信号的时域统计学特征，然后利用所有提取的特征运用 SVM、逻辑回归两种方法建立分类模型。但两种模型的分类结果并不理想，二者的准确率均低于 40%。其中，SVM 虽然整体的准确率略高于逻辑回归，但其在愤怒、轻松两个情感标签中并没有任何样本分入。这种结果并不利于后续只针对脑电信号识别其情感特征。

六、实践总结

本次实验目的为通过提取脑电信号特征对人的情绪进行分类。在实验过程中，首先，对于人的脑电信号有了初步的认识和理解；其次，我学习到了如何通过傅里叶变换将时域信号转换为频域信号，并在此基础上提取 PSD 特征，这个过程不但加深了我对于傅里叶变换理论

的理解，对功率谱密度的认识，同时极大地锻炼了我的动手实践能力；此外，我运用 SVM 及逻辑回归算法实验了多分类，对这两种算法的应用也更加熟练。

但是这次对于脑电信号的情感分类中，两种模型的分类结果并不理想，其主要问题在于两个模型都将大部分样本分入开心这一标签中，结合九个特征的小提琴图，我猜测模型分类准确率不高的原因可能为特征选取的问题。以后可以在这方面加强专业知识，选择更好的特征进行分类。